МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ВЯТСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
Институт математики и информационных систем
Факультет автоматики и вычислительной техники
Кафедра электронных вычислительных машин

Отчёт по лабораторной работе №1
по дисциплине
«Машинное обучение»
«Полный цикл решения задачи классификации.»
«Линейные модели и стохастический градиент.»

Выполнил студент гр. ИВТб-2303-06-00 _____/Перевозчиков Д.А./

Проверил _____/Пащенко Д. Э./

Киров
2026

1 Цель работы

Изучить начальные способы решения задачи многоклассовой классификации, процесс предобработки данных перед обучением моделей. Самостоятельно реализовать алгоритм стохастического градиентного спуска (SGD), исследовать влияние темпа обучения и L2-регуляризации, научиться подбирать гиперпараметры библиотечных моделей и оценивать качество их предсказаний.

2 Вариант и данные

Особенности набора: Все 64 признака являются числовыми (коэффициенты Кархунена-Лоэва, описывающие форму объектов). Пропуски отсутствуют. Датасет сбалансирован (ровно 200 объектов на каждый из 10 классов), поэтому применять методы борьбы с дисбалансом не требуется, однако macro-усреднение метрик для объективной оценки приходится применить.

Параметр	**Значение**
RANDOM_STATE	1004
Разбиение	`test_size=0.2`, `stratify=y`, 1600 объектов в Train и 400 в Test
Кросс-валидация	`StratifiedKFold(n_splits=5, shuffle=True)`
Основная метрика	`macro-F1` (так как классов 10, и они равнозначны)
Правила preprocessing	Так как пропусков нет, импутация данных не требуется. Все числовые признаки масштабируются с помощью `StandardScaler` для корректной работы градиентного спуска

Таблица 1: Параметры экспериментального протокола

3 Ход работы и результаты

3.1 Baseline

CV-метрики baseline: Accuracy = 0.1000, macro-F1 = 0.0182.

Поскольку в датасете 10 классов и они идеально сбалансированы, стратегия `most_frequent` просто угадывает один класс для всех объектов. Точность 10% и крайне низкий F1 подтверждают, что датасет не имеет тривиального доминирующего класса. Любая содержательная модель должна значительно превзойти эти значения, чтобы доказать, что она использует признаки, а не случайное угадывание.

3.2 SGD с нуля

В нашей реализации параметр τ отвечает за силу L2-регуляризации (штраф за рост весов). Параметр η – это темп обучения (learning rate).

Изучая таблицу зависимости качества от η (при фиксированном $\tau = 10^{-4}$), мы можем заметить, что при увеличении шага обучения с 0.0001 до 0.1000 финальное значение функции потерь у обучающей выборки падает с 0.2153 до 0.0048, что говорит о сходимости модели. Однако функция потерь у валидационной выборки ведет себя нелинейно, при $\eta = 0.0001$ значение функции = 0.2088 (модель не успевает сойтись), при $\eta = 0.01$ значение снижается до 0.0197, а при $\eta = 0.1$ функция достигает минимума 0.0161, но норма весов при этом вырастает до 8.7914. Из этого делаем вывод, что слишком большой шаг обучения приводит к росту нормы весов и риску переобучения. Оптимальным значением является $\eta = 0.01$.

η	final_train_loss	final_val_loss	weight_norm
0.0001	0.2153	0.2088	0.7944
0.0010	0.0511	0.0491	2.2124
0.0100	0.0149	0.0197	4.4856
0.1000	0.0048	0.0161	8.7914

Таблица 2: Влияние темпа обучения η на качество модели

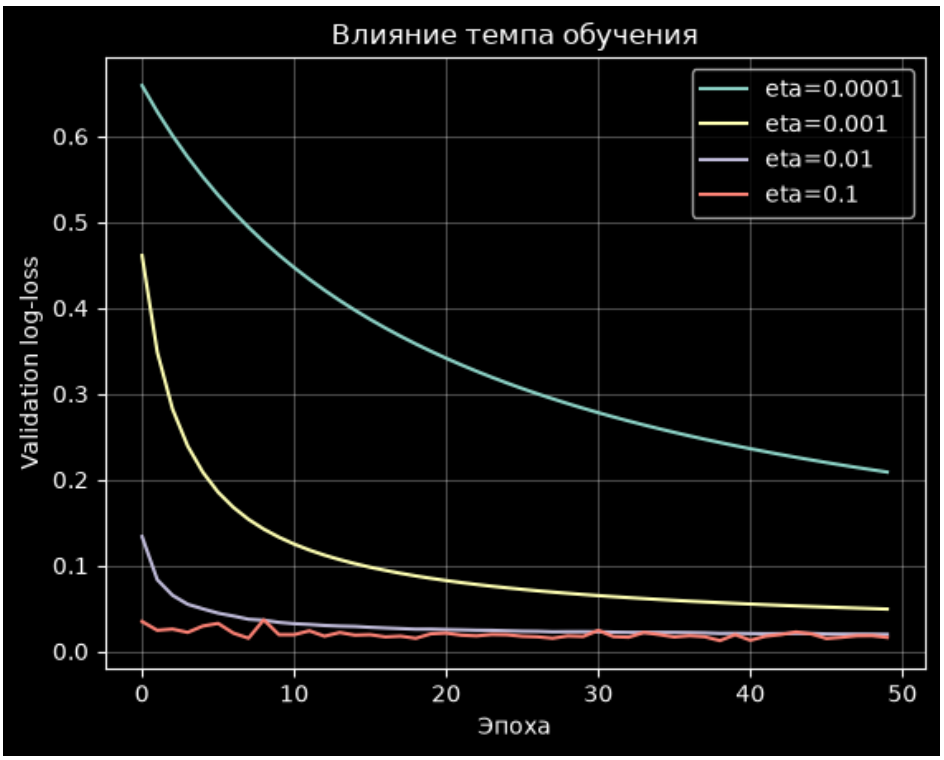


Рис. 1: Влияние темпа обучения η на validation loss

Влияние τ (при фиксированном $\eta = 0.01$): Изучая таблицу зависимости качества от τ, мы можем заметить, что при увеличении коэффициента регуляризации τ с 0.0000 до 0.0100 норма весов (`weight_norm`) существенно снижается с 9.8225 до 2.7894. Это подтверждает теорию: L2-регуляризация «сжимает» веса, не давая модели переобучаться. При этом `val_loss` растет с 0.0154 до 0.0491, так как модель становится более простой и жесткой, но это необходимая плата за обобщающую способность.

№	τ	val_loss	weight_norm
0	0.0000	0.0154	9.8225
1	0.0001	0.0161	8.7914
2	0.0100	0.0491	2.7894

Таблица 3: Влияние коэффициента регуляризации τ на качество модели

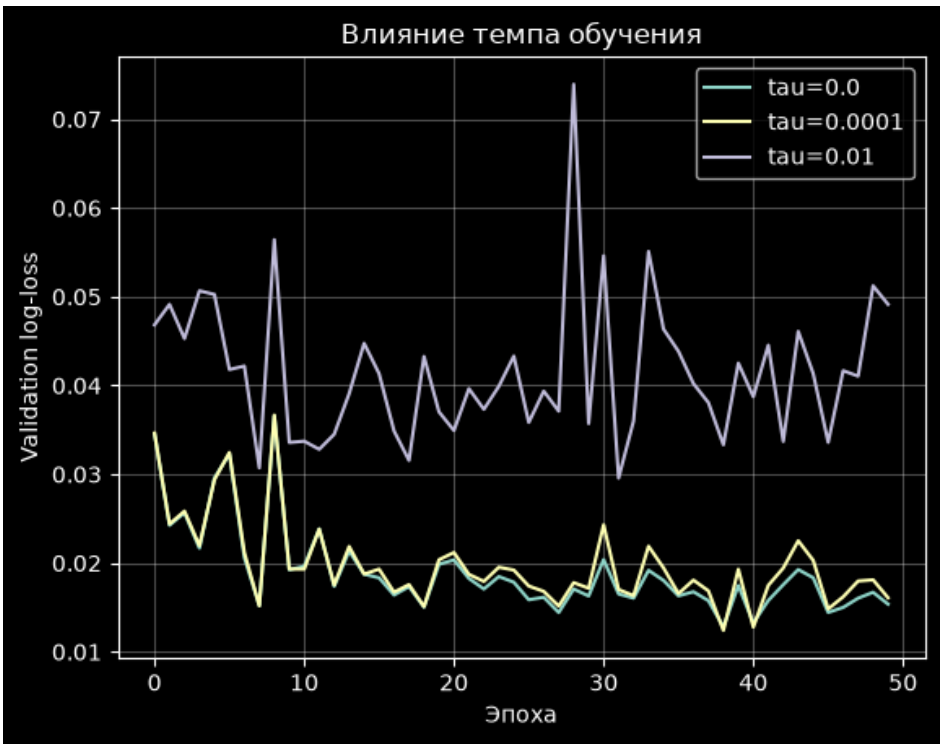


Рис. 2: Влияние коэффициента регуляризации τ на качество модели

3.3 Библиотечные модели

Для решения задачи был собран `Pipeline`, включающий `StandardScaler` и линейные классификаторы. Подбор гиперпараметров осуществлялся через `GridSearchCV` на кросс-валидации.

- **SGDClassifier:** Подбирались `eta0` (темп обучения) и `alpha` (регуляризация). Лучший результат CV macro-F1 = 0.9449 достигнут при `eta0 = 0.01`, `alpha = 0.01`.
- **LogisticRegression:** Подбирался параметр `C` (обратная сила регуляризации). Лучший результат CV macro-F1 = 0.9443 при `C = 0.1`.

Обе модели показали близкие результаты на кросс-валидации, что говорит о стабильности линейного разделения пространства признаков.

№	Модель	Лучшие параметры
1	SGDClassifier	`alpha=0.01, eta0=0.01`
2	LogisticRegression	`C=0.1`
0	DummyClassifier	`strategy=most_frequent`

Таблица 4: Сравнение моделей на кросс-валидации

3.4 Финальный test

На отложенной тестовой выборке `LogisticRegression` показала лучший результат (Accuracy = 0.9675, macro-F1 = 0.9675), чем `SGDClassifier` (Accuracy = 0.9600, macro-F1 = 0.9598). Обе модели значительно превзошли baseline.

№	Модель	Accuracy	Precision	Recall	F1-macro
0	DummyClassifier	0.1000	0.010	0.1000	0.0182
1	SGDClassifier	0.9600	0.961	0.9600	0.9598
2	LogisticRegression	0.9675	0.969	0.9675	0.9675

Таблица 5: Результаты на тестовой выборке

Класс	Precision	Recall	F1-score	Support
1	0.95	1.00	0.98	40
2	0.93	1.00	0.96	40
3	1.00	1.00	1.00	40
4	0.94	0.85	0.89	40
5	1.00	0.95	0.97	40
6	0.97	0.95	0.96	40
7	0.97	0.97	0.97	40
8	0.91	0.97	0.94	40
9	1.00	0.95	0.97	40
10	0.93	0.95	0.94	40
Accuracy		0.96		400
Macro avg	0.96	0.96	0.96	400
Weighted avg	0.96	0.96	0.96	400

Таблица 6: Отчет о классификации (LogisticRegression)

3.5 Анализ ошибок

Анализ таблицы наиболее уверенных ошибок показывает, что модель чаще всего ошибается на объектах классов **4, 5, 6, 8 и 10**. Наиболее характерные ошибки:

- Класс 4 путается с 8 (объект 602, confidence = 0.68) и с 2 (объект 649, confidence = 0.65).
- Класс 5 ошибочно классифицируется как 10 (объект 882, confidence = 0.66).
- Класс 8 путается с 10 (объект 1444, confidence = 0.52).
- Класс 4 путается с 1 (объект 792, confidence = 0.51).
- Класс 5 ошибочно предсказывается как 2 (объект 960, confidence = 0.49).

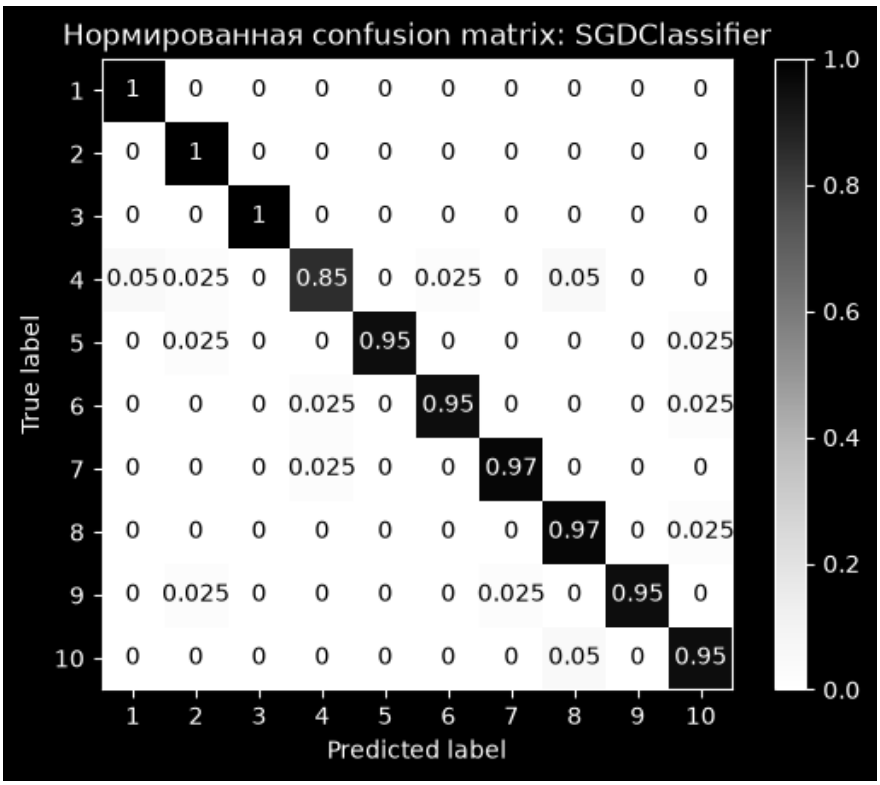


Рис. 3: Матрица ошибок (Confusion Matrix) для LogisticRegression

- Класс 6 путается с 4 (объект 1092, confidence = 0.48) и с 10 (объект 1069, confidence = 0.47).
- Класс 10 путается с 8 (объект 1939, confidence = 0.47).

Интерпретация причин ошибок:

1. **Линейная неразделимость:** Датасет `mfeat-karhunen` описывает формы объектов через коэффициенты Кархунена. Некоторые цифры похожи друг на друга и выдают близкие значения в пространстве признаков по некоторым соседним признакам.
2. **Пересечение классов:** Объекты классов 6 и 10, а также 4 и 8 имеют близкие значения признаков (например, по `att1`, `att2`), из-за чего модель выдает высокую уверенность, но ошибается в выборе.
3. **Шум в данных:** Некоторые объекты имеют аномальные значения признаков, что смещает линейную оценку.

Idx	att1	att2	att4	att7	true	pred	conf
602	14.22	5.82	2.30	-1.67	4	8	0.68
882	-3.18	-5.16	7.90	-3.14	5	10	0.65
649	5.36	5.73	9.23	-1.70	4	2	0.65
652	-2.07	-1.71	10.75	-0.59	4	8	0.57
1444	4.67	-7.92	3.44	0.65	8	10	0.52
792	-5.48	-1.55	8.86	-8.87	4	1	0.51
960	-0.18	7.61	4.62	1.04	5	2	0.48
1092	-9.08	-3.57	6.25	-3.71	6	4	0.47
1939	13.38	-0.24	-4.63	-3.68	10	8	0.47
1069	-0.78	-1.67	-2.13	-5.11	6	10	0.47

Таблица 7: Примеры наиболее уверенных ошибок классификации (ключевые признаки)

3.6 Анализ коэффициентов

Анализ коэффициентов модели `LogisticRegression` для класса 1 показывает, что наиболее важными признаками являются `att1` (коэффициент -1.007), `att7` (-0.934), `att2` (-0.907), `att4` (-0.472) и `att20` (0.450). Эти признаки вносят наибольший вклад в разделение класса 1 от остальных. Отрицательные коэффициенты означают, что увеличение значения признака снижает вероятность принадлежности к классу 1.

№	Признак	|Коэффициент|
0	num__att1	1.006667
6	num__att7	0.934140
1	num__att2	0.907004
3	num__att4	0.471681
19	num__att20	0.450484
9	num__att10	0.442513
4	num__att5	0.436300
13	num__att14	0.428139
25	num__att26	0.422736
18	num__att19	0.420888
22	num__att23	0.377420
21	num__att22	0.368085
5	num__att6	0.355352
10	num__att11	0.334465
8	num__att9	0.296371

Таблица 8: Топ-15 наиболее важных признаков для класса 1

Выводы

1. Базовая модель (`DummyClassifier`) подтвердила, что обычное угадывание на сбалансированном 10-классовом датасете дает macro-F1 всего 0.0182. Это даёт нам нижнюю границу для оценки качества более "умных"моделей.

2. При ручной реализации SGD было выявлено, что увеличение шага обучения η сверх меры (0.1) приводит к росту нормы весов до 8.7914: значение функции потерь на обучающей выборке падает до 0.0048, на валидационной достигает 0.0161. Оптимальным балансом между сходимостью и устойчивостью оказалось $\eta = 0.01$.

3. Увеличение коэффициента L2-регуляризации τ с 0 до 0.01 привело к снижению нормы весов с 9.8225 до 2.7894, что показывает работу

штрафа за сложность модели.

4. Усвоены принципы построения `Pipeline` и разделения Train/Test/CV.

5. Сравнение библиотечных моделей показало, что `LogisticRegression` (F1=0.9675 на test) работает немного стабильнее, чем `SGDClassifier` (F1=0.9598), хотя на CV они показали близкие результаты (0.9443 и 0.9449 соответственно).